

Predicción de Ingresos con Machine Learning

Asier Rodríguez | Bootcamp de Data Science

PROYECTO INDIVIDUAL



Made with GAMMA

Problema de Negocio

El Desafío

Una cadena de librerías con múltiples tiendas y canales de venta necesita predecir sus ingresos mensuales para optimizar la planificación financiera y la toma de decisiones operativas.

Objetivo del Proyecto

Desarrollar un modelo de machine learning capaz de predecir con precisión los ingresos netos mensuales (`net_revenue`), capturando tendencias, estacionalidad y diferencias entre tiendas y canales.



Dataset y Variables

Fuente de Datos

Dataset de ventas y payroll de una cadena de librerías

- Periodo: 2019–2024
- Entrenamiento principal: desde 2020
- Más de 1.000 observaciones mensuales

Variable Objetivo

net_revenue: ingresos netos mensuales

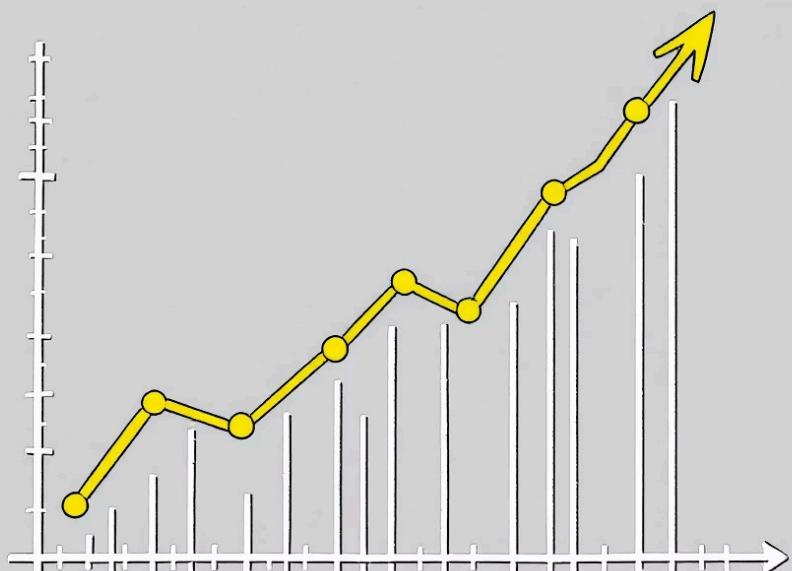
Variables Principales

- date
- store_id
- channel (IN_STORE / ONLINE)
- transactions
- payroll (análisis complementario)



Exploratory Data Analysis

HALLAZGOS CLAVE



Tendencia Creciente

Los ingresos muestran una tendencia ascendente desde 2020, con recuperación post-COVID

Estacionalidad Clara

Picos consistentes en septiembre (vuelta al cole) y diciembre (Navidad)

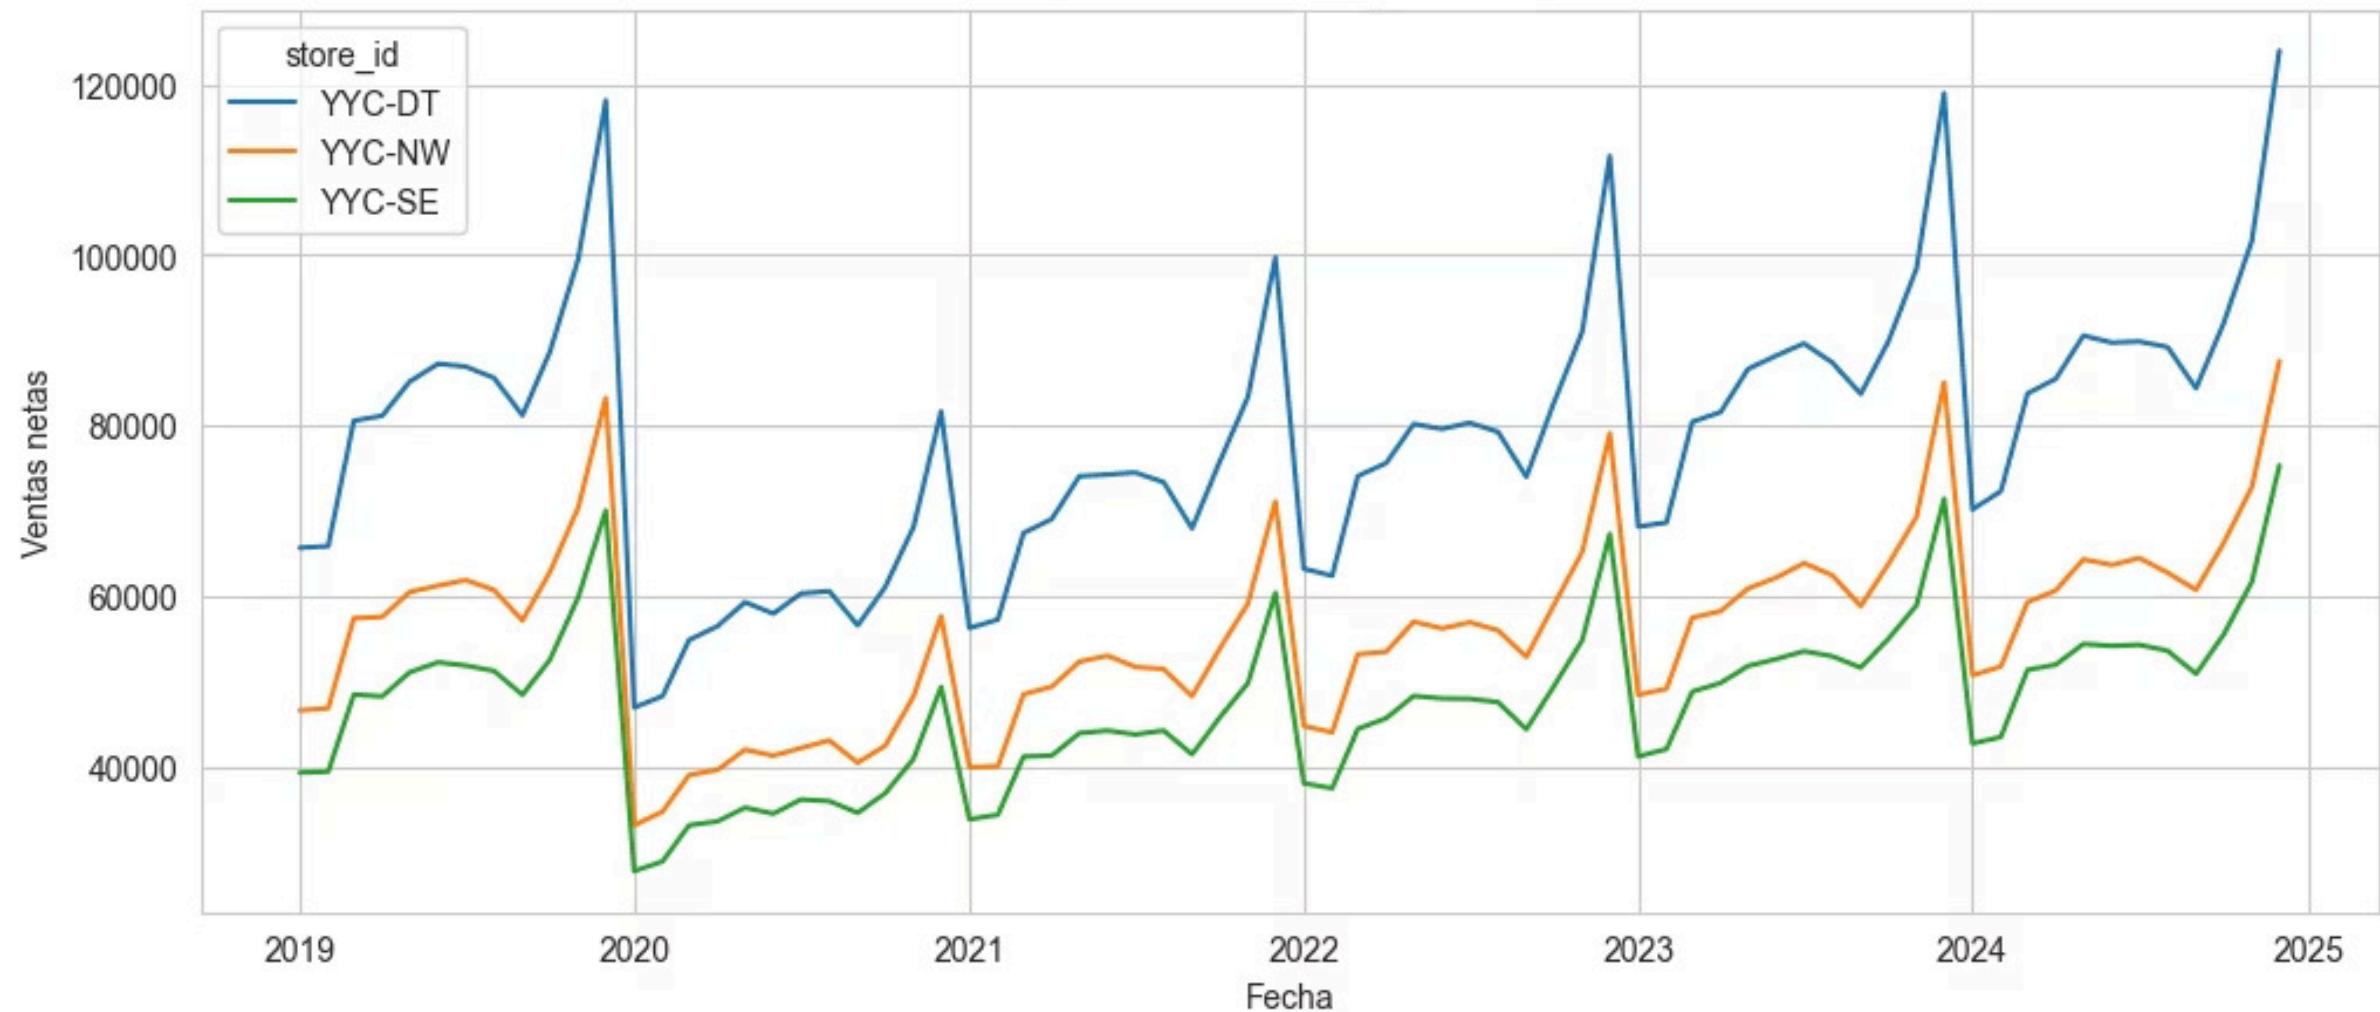
Impacto del COVID-19

Efecto evidente en 2020 con posterior recuperación

Diferencias Entre Canales

Comportamiento diferenciado entre tiendas físicas y canal online

Ventas mensuales por tienda





Feature Engineering

Features Temporales

Lags de ingresos:

- 1, 3, 6 y 12 meses

Rolling means:

- 3, 6 y 12 meses

Features Calculadas

Avg_ticket:

$\text{net_revenue} / \text{transactions}$

Indica el valor medio por transacción

Encoding Categórico

One-hot encoding de:

- store_id
- channel
- month

Modelos Evaluados



SARIMA

Modelo benchmark clásico de series temporales para capturar estacionalidad y tendencia



Regresión Lineal

Modelo lineal con features temporales, interpretable y estable



Random Forest

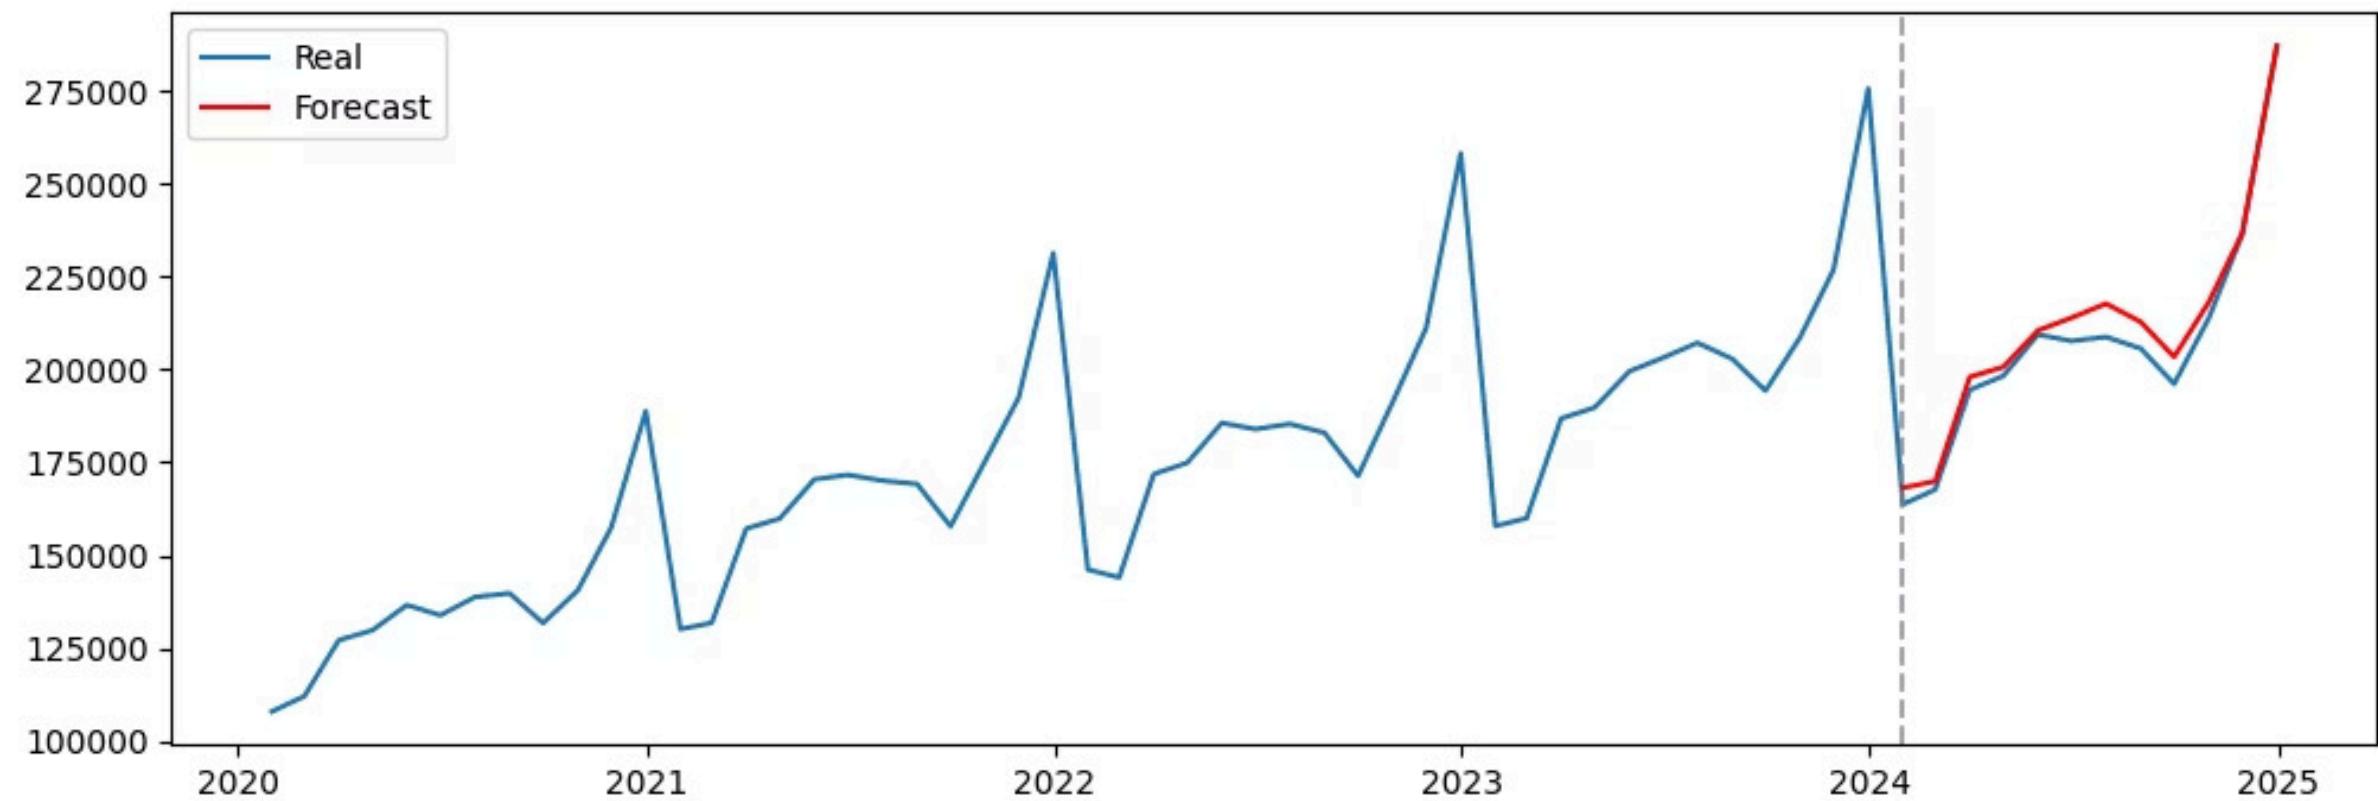
Ensemble de árboles de decisión para capturar relaciones no lineales



XGBoost

Gradient boosting avanzado, potente para predicciones complejas

Forecast SARIMA – Net Revenue mensual



Estrategia de Validación



01

Validación Temporal Estricta

Se respeta el orden cronológico de los datos para evitar data leakage y garantizar resultados realistas

02

Conjunto de Test

Los últimos 12 meses se reservan como conjunto de test para evaluar el rendimiento del modelo

03

Métricas de Evaluación

MAE (Mean Absolute Error) y **RMSE** (Root Mean Squared Error) para medir precisión



Resultados del Modelo Final



Modelo Seleccionado

Regresión Lineal con features temporales



Mejor Error en Test

Logra el mejor equilibrio entre precisión y estabilidad en el conjunto de validación



Estabilidad

Predicciones consistentes sin sobreajuste, rendimiento robusto en datos nuevos



Interpretabilidad

Coeficientes claros que permiten entender qué variables impactan más en los ingresos

El modelo captura efectivamente la tendencia y estacionalidad de los ingresos, siendo apto para producción y planificación financiera.



Puntuaciones de los modelos

Sarima

- RMSE → 4879
- MAE → 4002

RandomForest

- RMSE → 5559
- MAE → 3870

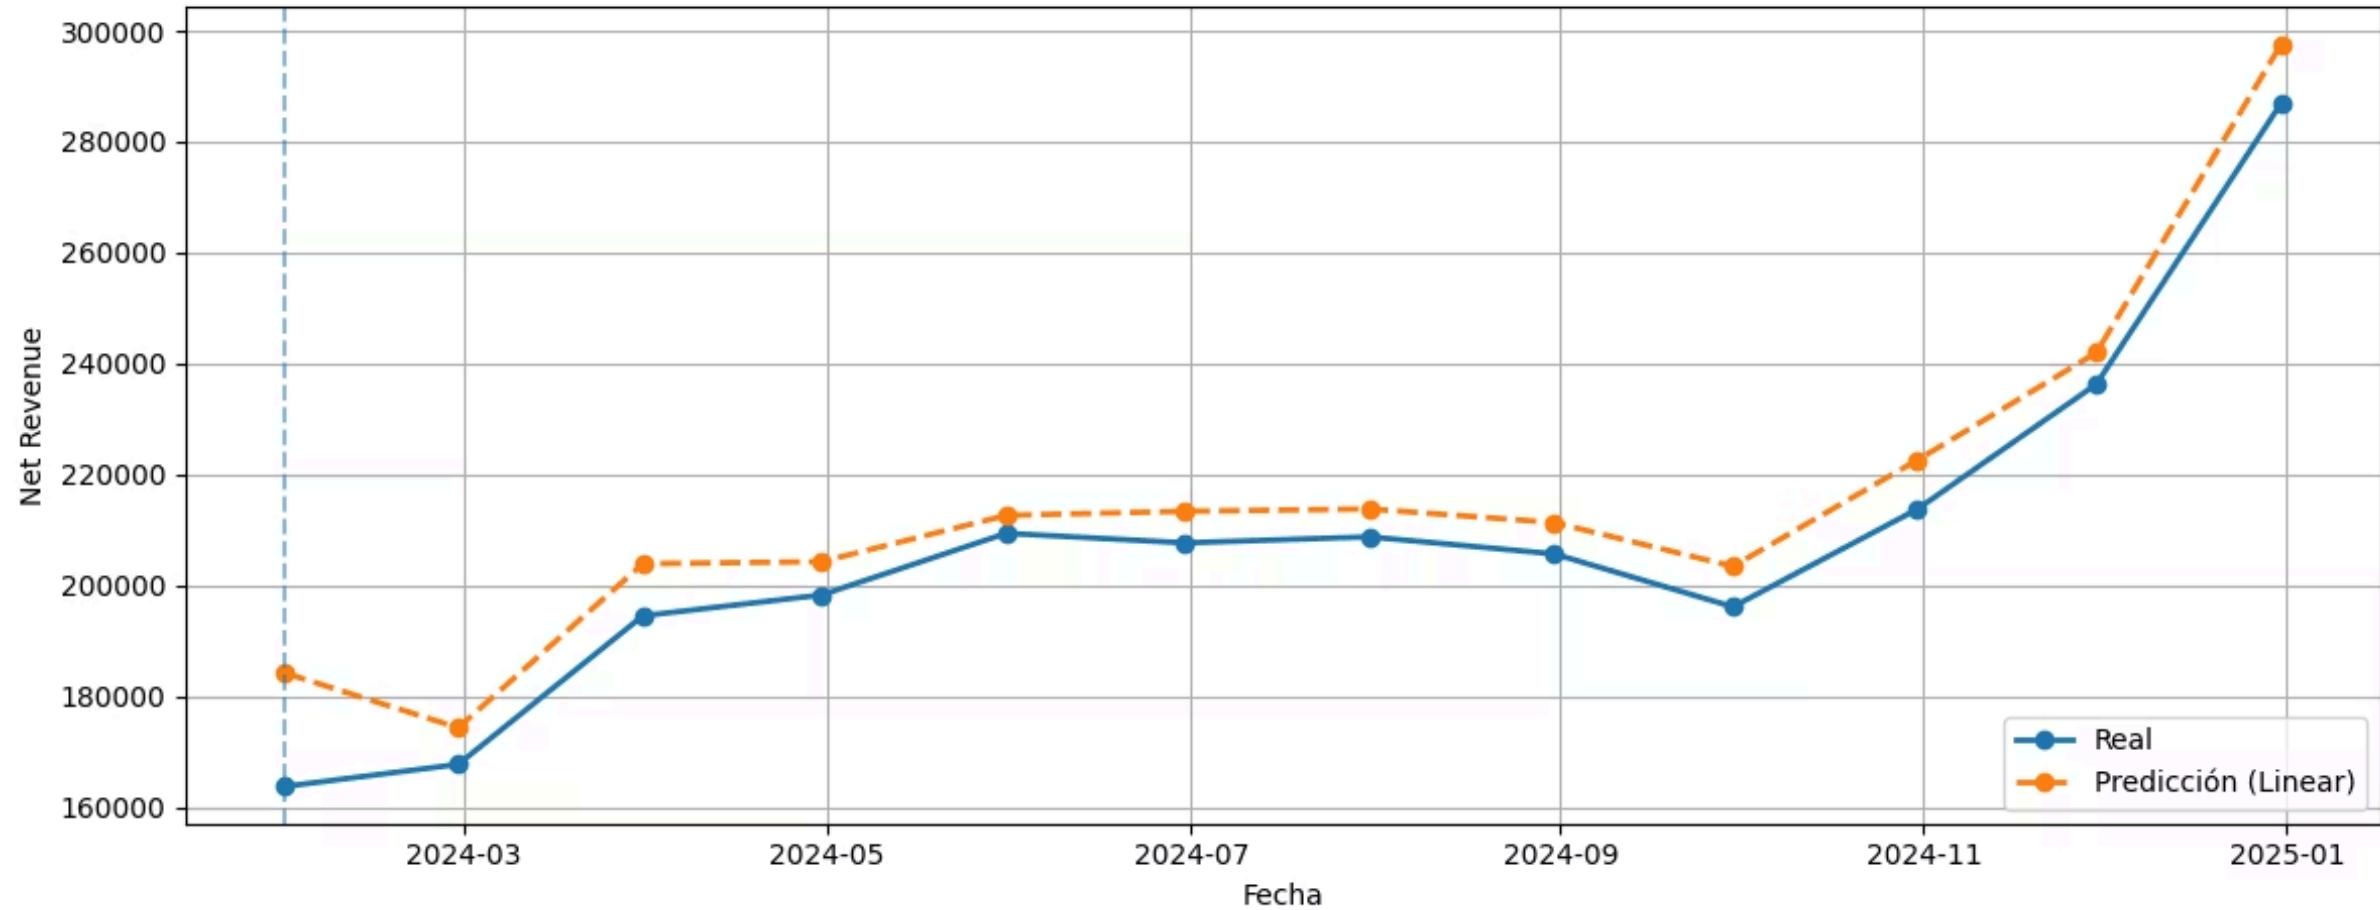
LinearRegression

- RMSE → 2663
- MAE → 1803

XGBoost

- RMSE → 4048
- MAE → 2742

Real vs Predicción mensual (H=12)



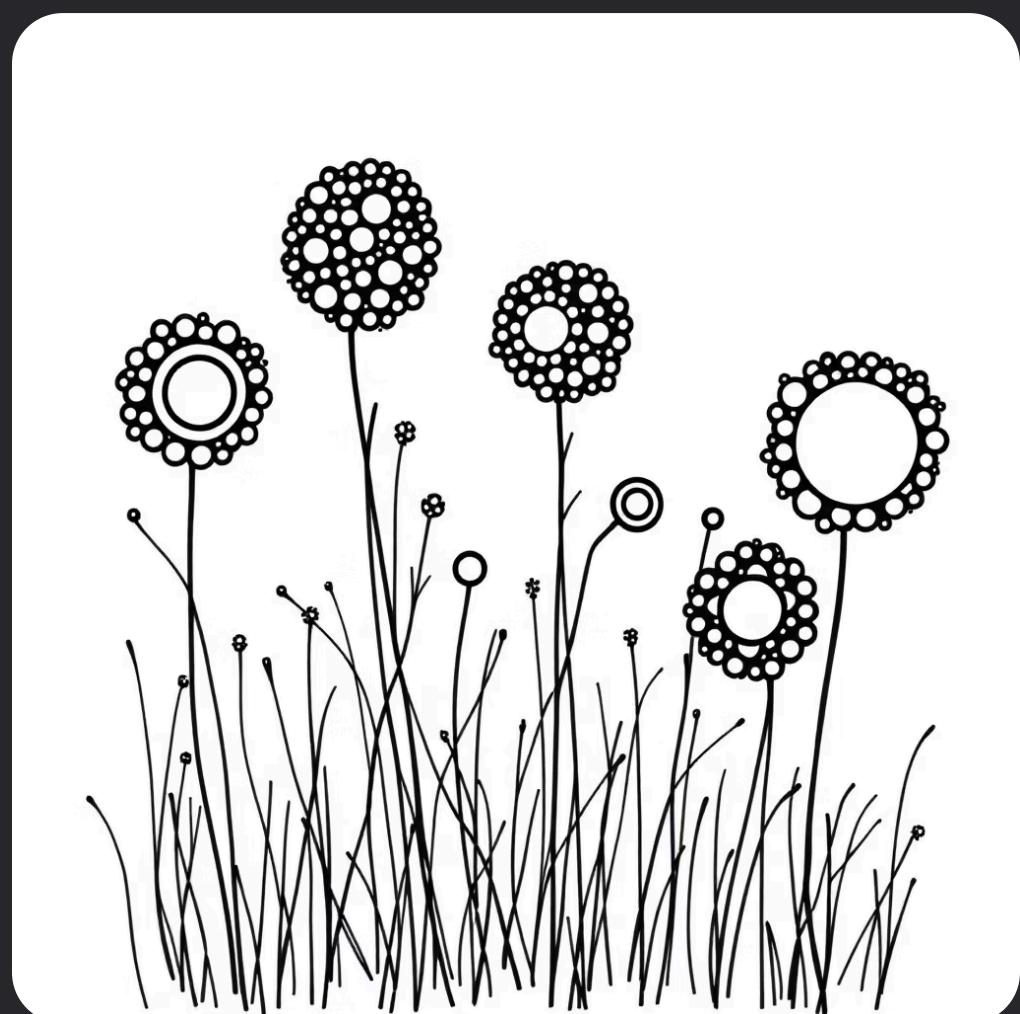
Análisis de Payroll

ANÁLISIS NO SUPERVISADO

Isolation Forest



KMeans Clustering



Detección de anomalías en payroll

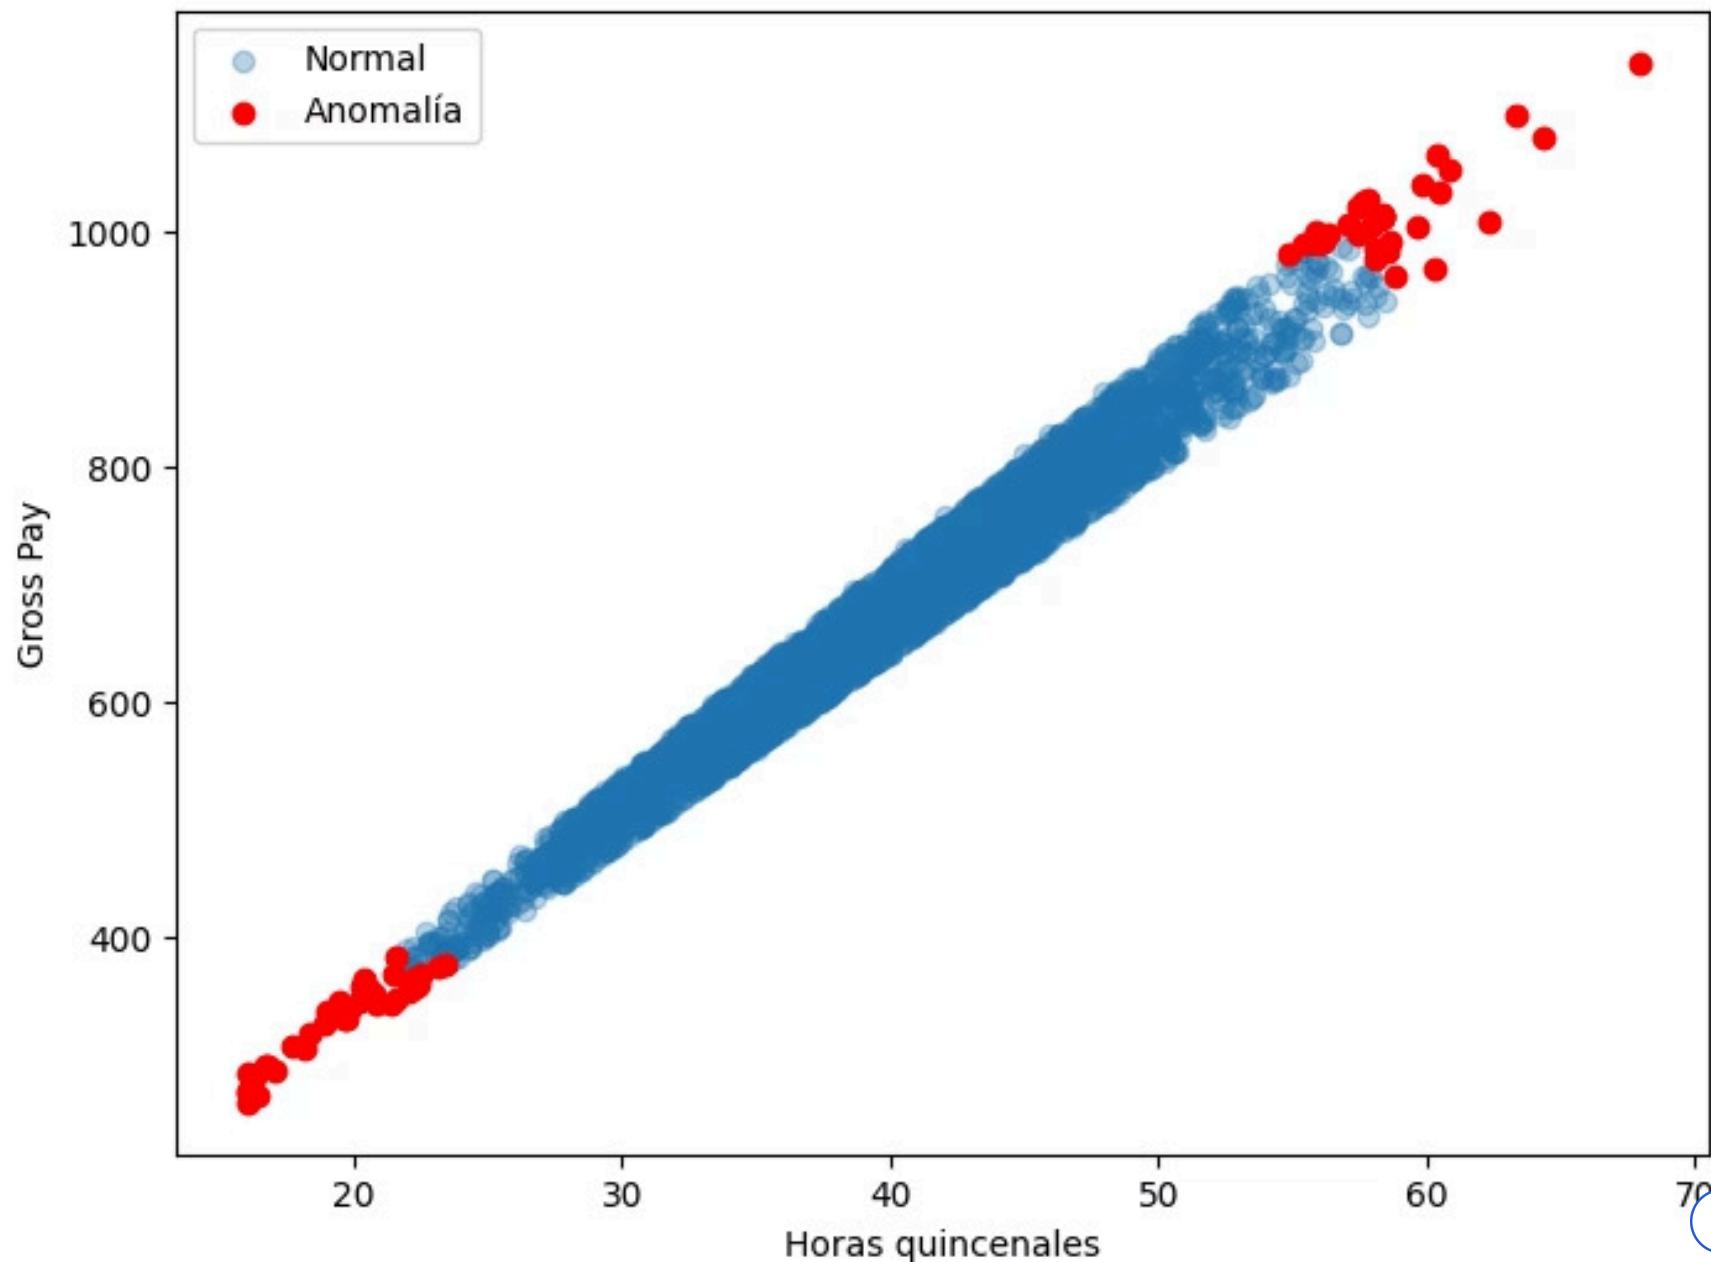
Identifica meses con gastos salariales inusuales que requieren revisión o investigación adicional

Segmentación salarial en 3 clusters

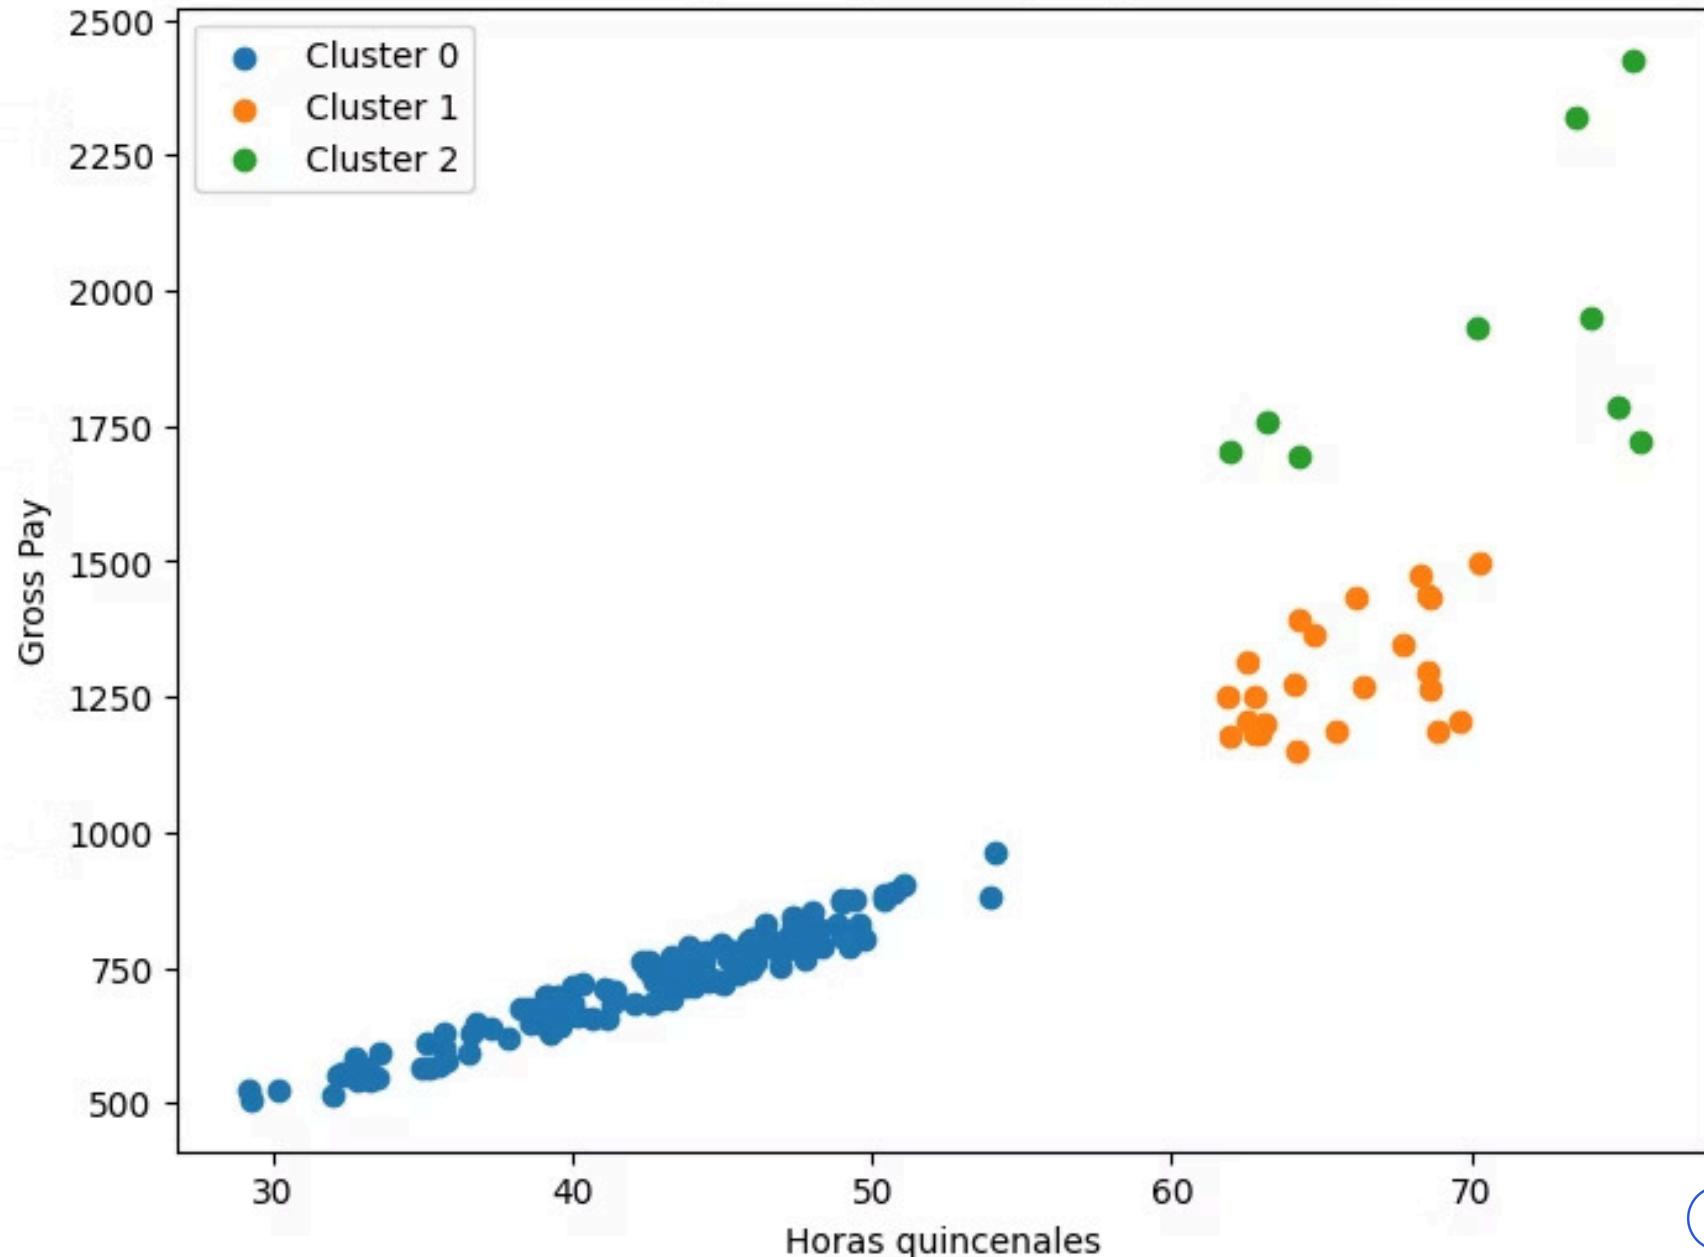
Agrupa meses según patrones de payroll para apoyar decisiones de gestión de personal

- Este análisis complementario no se usa para predicción directa, sino para identificar patrones y apoyar decisiones operativas

Anomalías dentro del rol: Seasonal Associate



Clustering de empleados por perfil salarial





Conclusiones y Próximos Pasos

Logros del Proyecto

- Modelo captura tendencia y estacionalidad con precisión
- Alta interpretabilidad para stakeholders
- Preparado para apoyar planificación financiera
- Útil para decisiones operativas informadas

Limitaciones

- No incluye variables externas (economía, marketing, competencia)
- Scope limitado a datos históricos internos

Mejoras Futuras

- Incorporar variables externas (indicadores económicos, campañas)
- Explorar modelos más complejos (LSTM para patrones profundos)
- Automatización del pipeline y despliegue en producción